

Entropía como número promedio de preguntas binarias

Lo que se va a probar

Se tiene una variable aleatoria X que puede tomar los valores $x_1, \dots, x_n$ con probabilidades $p_i = P(X = x_i)$. La idea es demostrar dos cosas:

1. Que para un mensaje de probabilidad p_i hacen falta $-\log_2 p_i$ preguntas de sí/no para identificarlo.
2. Que al promediar esas preguntas sobre todos los mensajes sale la fórmula de la entropía

$$H(X) = -\sum_{i=1}^n p_i \log_2 p_i.$$

La idea de fondo es que cada pregunta binaria da un bit de información, así que “cuántas preguntas necesito” es lo mismo que “cuántos bits ocupa el mensaje”.

Primer caso: n mensajes igual de probables

Supongamos que los n mensajes son equiprobables, o sea $p_i = 1/n$ para todos. Queremos saber cuál ocurrió haciendo preguntas de sí/no, y queremos hacer las menos posibles.

La mejor forma es por búsqueda binaria: cada pregunta parte en dos mitades las posibilidades que quedan (“¿está en la primera mitad?”). Con una pregunta pasamos de n a $n/2$ candidatos, con dos preguntas a $n/4$, y en general después de k preguntas quedan $n/2^k$ candidatos. Para quedar con uno solo se necesita

$$\frac{n}{2^k} = 1 \implies 2^k = n \implies k = \log_2 n.$$

Dicho de otra forma: con k preguntas binarias se distinguen a lo sumo 2^k cosas, así que para distinguir n mensajes se necesitan $k \geq \log_2 n$.

Como aquí $p = 1/n$, se tiene $n = 1/p$ y entonces

$$k = \log_2 n = \log_2 \frac{1}{p} = -\log_2 p.$$

O sea que un mensaje de probabilidad p cuesta $-\log_2 p$ preguntas. Tiene sentido: mientras más raro es el mensaje (menor p), más preguntas se necesitan para llegar a él.

El caso general (probabilidades distintas)

Cuando las probabilidades no son iguales ya no se puede partir todo en mitades exactas, pero la idea sigue igual: queremos darle a cada mensaje un código de ℓ_i bits (que es lo mismo que ℓ_i preguntas), y darle códigos cortos a los mensajes más frecuentes.

Para que el código se pueda decodificar sin ambigüedad, las longitudes tienen que cumplir la desigualdad de Kraft:

$$\sum_{i=1}^n 2^{-\ell_i} \leq 1.$$

Si se elige justo $\ell_i = -\log_2 p_i$, entonces $2^{-\ell_i} = p_i$ y la suma da

$$\sum_{i=1}^n 2^{-\ell_i} = \sum_{i=1}^n p_i = 1,$$

que cumple Kraft. Así que esa elección es válida y además no desperdicia nada. Con esto queda que la cantidad ideal de preguntas para el mensaje i es

$$\ell_i = -\log_2 p_i = \log_2 \frac{1}{p_i},$$

que es lo mismo que salió en el caso equiprobable, solo que ahora vale para cada mensaje por separado.

(En la práctica $-\log_2 p_i$ casi nunca da un entero, pero se puede llegar tan cerca como uno quiera codificando bloques de varios mensajes a la vez. Eso es lo que dice el teorema de codificación de fuentes de Shannon, así que se toma como el valor ideal.)

Entropía

Sabemos cuántas preguntas cuesta cada mensaje: el mensaje i cuesta $-\log_2 p_i$. Pero no todos los mensajes aparecen igual de seguido, entonces lo que tiene sentido es el promedio, pesando cada mensaje por su probabilidad de salir.

El promedio (valor esperado) del número de preguntas es

$$H(X) = \sum_{i=1}^n p_i \cdot (\text{preguntas del mensaje } i) = \sum_{i=1}^n p_i \cdot (-\log_2 p_i) = -\sum_{i=1}^n p_i \log_2 p_i,$$

que es exactamente la fórmula que quería demostrar.

En palabras: la entropía es el número promedio de preguntas de sí/no que se necesitan para adivinar el resultado de X . Es la cantidad de información promedio que trae la variable, medida en bits.

Comprobación rápida

Si X tiene un solo resultado posible ($p = 1$), entonces $H(X) = -1 \cdot \log_2 1 = 0$: no se necesita preguntar nada porque ya se conoce qué va a salir. Y si se tienen n resultados equiprobables, cada uno con $p = 1/n$,

$$H(X) = -\sum_{i=1}^n \frac{1}{n} \log_2 \frac{1}{n} = -n \cdot \frac{1}{n} \log_2 \frac{1}{n} = \log_2 n,$$

que coincide con las $\log_2 n$ preguntas de la búsqueda binaria del principio. Así que la fórmula da lo que uno espera en los dos casos extremos.