

¿Quién controla mejor el número de datos N : ϵ o δ ?

Planteamiento

La desigualdad de Hoeffding con M hipótesis da la cota

$$P[|E_{\text{in}} - E_{\text{out}}| > \epsilon] \leq 2Me^{-2N\epsilon^2} = \delta,$$

donde ϵ es la tolerancia (qué tan aproximada es la estimación) y δ el nivel de confianza (qué tan probable es fallar). Para comparar el efecto de cada uno sobre el tamaño de la muestra, conviene despejar N .

Despeje de N

Partiendo de $\delta = 2Me^{-2N\epsilon^2}$:

$$e^{-2N\epsilon^2} = \frac{\delta}{2M} \implies -2N\epsilon^2 = \ln\left(\frac{\delta}{2M}\right) \implies \boxed{N = \frac{1}{2\epsilon^2} \ln\left(\frac{2M}{\delta}\right)}.$$

La forma de esta expresión ya contesta la pregunta:

$$N \propto \frac{1}{\epsilon^2} \quad \text{mientras que} \quad N \propto \ln \frac{1}{\delta}.$$

La dependencia en ϵ es *polinómica inversa de orden dos*, y la dependencia en δ es solo *logarítmica*. Un logaritmo crece muy despacio, así que exigir más confianza cuesta poco, mientras que exigir más precisión cuesta mucho.

Comparación cuantitativa

Midiendo la sensibilidad relativa (elasticidad) de N frente a cada parámetro:

$$\frac{\epsilon}{N} \frac{\partial N}{\partial \epsilon} = -2, \quad \frac{\delta}{N} \frac{\partial N}{\partial \delta} = -\frac{1}{\ln(2M/\delta)}.$$

La primera es constante e igual a -2 : bajar ϵ un 1 % sube N un 2 %, siempre. La segunda es pequeña y además se hace más pequeña a medida que δ baja, porque el $\ln(2M/\delta)$ del denominador crece.

Con $M = 1$, $\epsilon = 0,1$ y $\delta = 0,05$ se obtiene $N \approx 185$. Partiendo de ahí:

Cambio	N	factor
(caso base) $\epsilon = 0,1$, $\delta = 0,05$	185	1,00
ϵ a la mitad (0,05)	738	4,00
ϵ a la cuarta parte (0,025)	2952	16,00
δ a la mitad (0,025)	220	1,19
δ dividido por 10 (0,005)	300	1,62
δ dividido por 100 (0,0005)	415	2,25

Reducir ϵ a la mitad multiplica N por 4; reducirlo a la cuarta parte lo multiplica por 16. En cambio, dividir δ entre 100 apenas duplica N .

Conclusión

El parámetro que controla de mejor manera el número de datos es ϵ . Es el que domina la expresión $N = \frac{1}{2\epsilon^2} \ln(2M/\delta)$, y por tanto la palanca real sobre el tamaño de la muestra: pequeños cambios en la tolerancia producen cambios grandes en N , con un crecimiento cuadrático inverso. El parámetro δ influye de forma muy débil, porque entra logarítmicamente; eso es conveniente en la práctica, ya que se puede pedir una confianza altísima sin pagar casi nada en datos.

Vale la pena notar que M también entra de forma logarítmica, ya que $\ln(2M/\delta) = \ln M + \ln(2/\delta)$. Es decir, agregar hipótesis al modelo resulta igual de barato que aumentar la confianza; lo caro es pedir precisión.