

Factorización de matrices en el Reto Netflix: el método ganador del KDD Cup 2007 (Task 1)

El problema

El KDD Cup 2007 Task 1, “Who Rated What in 2006”, usó el conjunto de datos del Netflix Prize. La tarea era predecir, para una lista de 100,000 pares usuario–película, la probabilidad de que el usuario hubiera calificado esa película en 2006. En el Reto Netflix original la meta relacionada es completar una matriz de calificaciones enorme y casi vacía: se conocen unas pocas entradas (las películas que cada usuario sí calificó) y se quiere estimar el resto.

Lo que se tiene es entonces una matriz W de usuarios por películas. En este reporte la matriz es de tipo 0–1 (vale 1 si el usuario i calificó la película j , y 0 en otro caso); es una matriz no negativa y muy dispersa, porque cada usuario calificó solo una fracción diminuta del catálogo. El problema central es reconstruir las entradas desconocidas de W a partir de las pocas conocidas, y la herramienta principal para lograrlo es la factorización de matrices.

La idea de la factorización: una capa de temáticas latentes

La factorización parte de una suposición sencilla: aunque hay millones de pares usuario–película, en el fondo el gusto se explica por unos pocos ejes ocultos, que llamaremos *temáticas* (acción, romance, humor, cine de autor, etc., aunque nunca se etiquetan de forma explícita). La idea es meter esa capa intermedia de temáticas entre los usuarios y las películas, y describir todo en términos de ella.

Esto da dos paralelos, que son las dos matrices de la factorización:

- **Usuarios vs. temáticas.** A cada usuario se le asocia un vector que dice cuánto le atrae cada temática. Esto forma una matriz U de tamaño (usuarios $\times$ temáticas): la fila u es el perfil de gustos del usuario u .
- **Temáticas vs. películas.** A cada película se le asocia un vector que dice cuánto pertenece a cada temática. Esto forma una matriz V de tamaño (películas $\times$ temáticas), o su transpuesta $V^\top$ de tamaño (temáticas $\times$ películas): la columna j dice de qué temáticas está hecha la película j .

Además, una matriz diagonal Σ pesa la importancia de cada temática (unas explican más varianza del gusto que otras). Con esto, la matriz completa se aproxima como

$$W \approx U \Sigma V^\top.$$

Cómo se deduce el comportamiento a partir del paralelo

El punto clave es que las dos matrices comparten el mismo eje: las temáticas. Entonces el paralelo “usuarios vs. temáticas” se puede encadenar con el paralelo “temáticas vs. películas” a través de ese eje común, y lo que queda es el paralelo que interesa: “usuarios vs. películas”.

En fórmulas, la predicción para el par (u, j) es

$$\hat{w}_{uj} = \sum_{\ell=1}^k \sigma_{\ell} u_{u\ell} v_{j\ell},$$

es decir, temática por temática se multiplica cuánto le gusta esa temática al usuario por cuánto la ofrece la película, y se suma todo. El comportamiento que se deduce es intuitivo: la predicción es alta cuando el perfil del usuario y el de la película coinciden en las mismas temáticas, y baja cuando no. Un usuario que puntúa alto en “acción” y bajo en “romance” recibirá valores altos justo para las películas que puntúan alto en “acción”.

El número de temáticas k (el rango de la aproximación) es pequeño frente al tamaño de la matriz. Esa reducción es lo que hace que el método funcione: al obligar a explicar todo con pocas temáticas, la factorización se queda con los patrones de gusto más generales y descarta el ruido de las calificaciones individuales. Por eso puede rellenar pares que nunca vio: si el usuario y la película caen en temáticas compatibles, el producto de sus perfiles ya da una estimación razonable aunque esa entrada concreta fuera desconocida.

SVD y el teorema de Eckart–Young

La factorización concreta que usa el reporte es la descomposición en valores singulares (SVD). Para una matriz W de rango ρ se escribe $W = U^{\top} \Sigma V$ con U y V ortogonales y Σ diagonal con los valores singulares. La predicción se obtiene quedándose solo con las k temáticas más importantes (las de mayor valor singular): la aproximación de rango k

$$W \approx U_k \Sigma_k V_k^{\top},$$

donde U_k y V_k guardan las primeras k columnas y Σ_k los primeros k valores singulares.

Que esta sea la mejor elección posible lo garantiza el teorema de Eckart–Young: entre todas las matrices de rango k , la que se obtiene truncando la SVD es la que minimiza el error en norma de Frobenius,

$$\|W - U_k \Sigma_k V_k^{\top}\|_F^2 = \sum_{ij} \left(w_{ij} - \sum_{\ell} \sigma_{\ell} u_{\ell i} v_{\ell j} \right)^2.$$

Como esa norma de Frobenius es exactamente la suma de errores al cuadrado sobre todas las entradas, minimizarla equivale a hacer la mejor reconstrucción global de la matriz de calificaciones con solo k temáticas. Ese es el sentido en que la SVD “resuelve” el problema: encuentra las temáticas y los perfiles óptimos para reconstruir W .

El ajuste propio del artículo: SVD ponderada por el muestreo

Aquí el reporte hace una corrección importante. La norma de Frobenius trata por igual a todas las entradas, y eso sería lo correcto si los pares del Cup se hubieran elegido de forma uniforme. Pero no fue así: los pares se muestrearon con probabilidad p_{ij} proporcional a los márgenes (cuánto calificó el usuario y cuánto se calificó la película). Para alinear la factorización con la forma en que se evalúa la tarea, se minimiza una versión ponderada:

$$\sum_{ij} p_{ij} \left(w_{ij} - \sum_{\ell} \sigma_{\ell} u_{\ell i} v_{\ell j} \right)^2 = \sum_{ij} \left(\sqrt{p_{ij}} w_{ij} - \sqrt{p_{ij}} \sum_{\ell} \sigma_{\ell} u_{\ell i} v_{\ell j} \right)^2.$$

El truco es que el lado derecho vuelve a tener la forma de un problema de SVD ordinario, pero aplicado a la matriz $\sqrt{p_{ij}} w_{ij}$; luego el resultado se divide punto a punto por $\sqrt{p_{ij}}$ para recuperar la predicción. Así se aprovecha el mismo maquinaria de SVD respetando el muestreo.

En la práctica se usó una implementación basada en el método de Lanczos (la biblioteca SVDPACK), que resultó rápida y precisa. Se observó que subir el número de temáticas producía sobreajuste, así que se eligió una aproximación de $k = 10$ dimensiones. Con esas 10 temáticas, la distribución de los valores reconstruidos separa bien los pares que sí tenían calificación de los que no (los primeros toman valores más altos), que es justo lo que se quería predecir.

Cómo encaja en la solución final

La factorización por SVD no fue el único método: el reporte la combinó con una predicción base por independencia usuario–película, con un recomendador por similitud entre películas (coseno ajustado) y con reglas de asociación sobre secuencias de calificaciones. Todas esas predicciones se fusionaron con una regresión lineal (con la herramienta Weka), obteniendo una predicción final de la forma

$$0,5533 p_{um} + 0,029 (\text{correlación}) + 0,1987 (\text{SVD}) - 0,0121 (\text{reglas}) - 0,0042.$$

Esa combinación alcanzó un error cuadrático medio (rmse) de 0,256, por delante del segundo lugar (0,263) y de la predicción trivial de todo ceros (0,279). El peso de la SVD en la mezcla (0,1987) muestra que la factorización aportó una parte sustancial de la señal, complementando a la predicción base.

Resumen

El Reto Netflix se resuelve, en su núcleo, factorizando la matriz no negativa de calificaciones. La factorización introduce una capa de temáticas latentes y la describe con dos paralelos: usuarios vs. temáticas (matriz U) y temáticas vs. películas (matriz $V^{\top}$). Como ambos comparten el eje de las temáticas, al encadenarlos se reconstruye el paralelo usuarios vs. películas, y la predicción de cada par es el producto de los perfiles del usuario y de la película sobre las temáticas comunes. La SVD entrega esos perfiles de forma óptima (por Eckart–Young, la mejor aproximación de rango k en norma de Frobenius), y el rango bajo ($k = 10$) es lo que permite generalizar a los pares desconocidos. El reporte adapta esta idea al muestreo de la tarea con una SVD ponderada por $\sqrt{p_{ij}}$ y la combina con otros predictores mediante regresión lineal para llegar al resultado ganador.